

Tarea de Investigación y Práctica

Johnny Aarón Ortiz López

Facultad de Ciencias Matemáticas y Físicas, Universidad de Guayaquil

CDDEIA-ELNO-4-2: Ciencia de Datos e Inteligencia Artificial

Msc. Darwin Rodríguez

11 de junio de 2026

Parte 1: Informe comparativo de Métricas

1. Introducción

El diagnóstico asistido por computadora para la detección de cáncer de mama es un hito importante en la medicina moderna, por ello el diagnóstico de estos podría ayudar de forma significativa; para la presente investigación se clasificarán los tumores como: Maligno (Clase 0) y Benigno (Clase 1).

Un error de clasificación tiene repercusiones importantes, catalogar un tumor maligno como benigno (un falso negativo) puede retrasar la apertura a un tratamiento crítico y altamente necesario en que la mayoría de los casos toma vidas humanas, debido a no actuar a tiempo. Mientras que catalogar un tumor benigno como maligno (un falso positivo) induce a estrés psicológico, procesos médicos innecesarios e incluso tratamientos inadecuados que pueden causar importante daño a la salud de una persona.

2. Comparación de métricas de evaluación

Diccionario de variables previo:

- TP(True Positives / Verdaderos Positivos)
- FN (False Negatives / Falsos negativos)
- TP + FP (Total de predicciones positivas sin importar si acertó o falló)
- TP + FN (Total de positivos reales)

Precisión (Precision)

Mide la calidad de las predicciones positivas del modelo. Se define como $TP/(TP+FP)$. En nuestro modelo base, la precisión fue de 0.9467 (94,67%). Significa que de cada 100 pacientes el modelo etiquetó como benignos a 95 personas que realmente lo eran y 5 que era falso positivo, realmente eran malignos.

Sensibilidad (Recall)

Mide la capacidad del modelo para encontrar todos los casos positivos reales. Su fórmula es $TP/(TP+FN)$. El modelo base obtuvo un 0.9861 (98.61%). Lo que indica que el sistema es sumamente eficaz para capturas casos de las clases analizadas (0-1), dejando muy pocos pacientes sin diagnosticar correctamente (Falsos negativos).

F1-Score

Es la media entre Precisión y Recall, calculada como $2 * (\text{Precision} \times \text{Recall}) / (\text{Precisión} + \text{Recall})$. Se utiliza para evaluar el balance general del modelo cuando existe un costo compartido entre Falsos Positivos y Negativos. El valor fue de 0.9660.

AUC-ROC (Área bajo la curva ROC)

Mide la capacidad global del modelo para separar las clases de todos los umbrales posibles. Un valor de 0.5 representa una clasificación aleatoria. El modelo alcanzó el 0.9940, demostrando ser altamente capaz de diferencia tejido sano de tejido cancerígenos.

3. Justificación de la Métrica más adecuada

Enfocado en la detección de clase maligna de cáncer de mama, la métrica más crítica es la de Recall (sensibilidad).

Justificación:

En medicina, siempre es algo de prioridad disminuir los errores como los falsos negativos, casos donde el paciente está enfermo, pero vuelve a casa porque cree o los resultados de una prueba lo clasifican como alguien sano. Un Recall, alto aseguraría que casi la totalidad de los pacientes con tumores malignos sean detectados para recibir debida atención. Si bien el de Precisión, es importante para evitar levantar falsas alarmas como falsos positivos, en medicina, es en la mayoría por no decir todos los casos, someter a un paciente sano a estudios confirmatorios secundarios que permitir que un paciente con cáncer avanzado pase desapercibido por el algoritmo debido a estar en el rango de fallo.

Parte 3: Conclusiones Analíticas

Debido a la gran cantidad de pruebas de laboratorio realizados y a la par de clasificar debidamente la información para futuro análisis de métricas, esa estructura de información facilita obtener valiosas lecciones sobre el comportamiento de la Regresión logística.

1. ¿Qué método de búsqueda de hiperparámetros fue más eficiente?

El análisis comparativo determinó que RandomizedSearchCV demostró ser el método de búsqueda de hiperparámetros más eficientes en términos computacionales, mientras que GridSearchCV, ofreció una precisión superior en la métrica optimizada.

Especialmente, GridSearchCV, evaluó de forma exhaustiva el vector de opciones y encontró que los parámetros óptimos eran C: 10, penalty 12, con un F1-Score de 0.9596. Por su parte RandomizedSearchCV seleccionó de forma aleatoria un subconjunto de interacciones dando como mejor alternativa C: 100, penalty: 12 con un F1-Score de 0.9578. Aunque la diferencia es apenas del 0,18%, RandomizedSearchCV requiere una fracción del tiempo del procesamiento al no computar todas las combinaciones posibles. En entornos reales, donde los dataset presentan altos volúmenes, el ahorro en tiempo justifica sacrificar rendimiento si este no es significativamente mucho.

2. ¿Cómo afectó el ajuste del umbral a Precisión vs Recall?

El ajuste de umbral de decisión demostró de forma empírica la ley de compensación inversa entre la Precisión y el Recall, al evaluar un umbral bajo de 0,3, el modelo se volvió muy sensible, manteniendo el Recall máximo de 0.9861 pero sacrificando la Precisión a 0.9342, debido a una mayor tolerancia de admitir casos dudosos.

Elevar este umbral de 0,3 a 0,7, provocó que el modelo se tornara conservador, la Precisión alcanzó el 0.9857 (minimizando falsos positivos) pero el Recall disminuyó a 0.9583. El umbral intermedio de 0,5 actuó como el punto de equilibrio en esta investigación, permitiendo alcanzar el F1-Score más alto. 0.9726. Esto comprueba que el umbral no es estático y requiere calibración según las consecuencias del problema.

3. ¿y qué aprendiste sobre la elección de métricas?

Se aprendió que evaluar un modelo basándose únicamente en la Accuracy 0.9561 (exactitud), es un error importante. La exactitud puede camuflar deficiencias críticas si

las clases están mínimamente desbalanceadas. En la matriz de confusión (38 malignos correctamente predichos frente a 4 falsos positivos, y 71 benignos frente a 1 falso negativo), las métricas desagregadas como Precisión y Recall, permiten auditar el comportamiento específico del motor antes diversos errores particulares.

La validación cruzada K-fold, corroboró dicho aprendizaje, al comparar $K = 5$ (Exactitud: 0.9508, Desviación: 0.0263) y luego $K=10$ (Exactitud: 0.9490, Desviación: 0.0337), se evidenció que aumentar el valor, incrementa la variabilidad del rendimiento. Lo que permite deducir que el modelo no depende solo de su algoritmo, también de como están o se segmentan los datos y la precisión conceptual con la que se interpretarían los fallos.



Bibliografía

- Bello, K., Ibidoja, O. J., & Abubakar, Y. (Julio de 2024). *Predicting Students Academic Performance using Ridge, LASSO and Elastic Net with Efficient Model Selection: A Case Study of Federal*. Obtenido de University Gusau Nigeria: <https://fugus-ijsgs.com.ng/index.php/ijsgs/article/download/670/439/734>
- Berrar, D. (2019). *Cross-Validation*. Encyclopedia of Bioinformatics and Computational Biology. Obtenido de https://dberrar.github.io/papers/Berrar_EBCB_2nd_edition_Cross-validation_preprint.pdf
- Casal, R. F., Bouzas, J. C., & Fuente, M. O. (2024). *Métodos predictivos de aprendizaje estadístico*. Obtenido de Github: https://rubenfcasal.github.io/aprendizaje_estadistico/aprendizaje_estadistico.pdf
- Chicco, D., & Jurman, G. (2020). *The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation*. BMC Genomics. Obtenido de <https://link.springer.com/article/10.1186/s12864-019-6413-7>
- Fawcett, T. (2006). *An introduction to ROC analysis*. Pattern Recognition Letters. Obtenido de <https://people.inf.elte.hu/kiss/13dwhdm/roc.pdf>
- Geeks for Geeks . (12 de julio de 2025). *Lasso vs Ridge vs Elastic Net - ML*. Obtenido de <https://www.geeksforgeeks.org/machine-learning/lasso-vs-ridge-vs-elastic-net-ml/>
- Google Developer Program. (2026). *Sobreaajuste*. Obtenido de developers.google.com: <https://developers.google.com/machine-learning/crash-course/overfitting/overfitting?hl=es-419>
- Goutte, C., & Gaussier, B. (2005). *A Probabilistic Interpretation of Precision, Recall and F-Score, with Implication for Evaluation*. Lecture Notes in Computer Science. Obtenido de https://link.springer.com/chapter/10.1007/978-3-540-31865-1_25
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., . . . Duchesnay, E. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research. Obtenido de <https://jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf>
- Powers, D. M. (2011). *Evaluation: From Precision, Recall and F-Measure to ROC Informedness, Markedness and Correlation*. Cornell University. Obtenido de <https://arxiv.org/pdf/2010.16061>

Saito, T., & Rehmsmeier, M. (2015). *The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets*. PLOS One. Obtenido de <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0118432>

Valverde-Albacete, F. J., & Peláez-Moreno, C. (2014). *100% classification accuracy considered harmful*. PLOS One. Obtenido de <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0084217>

