

Tarea de Investigación y Práctica

Johnny Aarón Ortiz López

Facultad de Ciencias Matemáticas y Físicas, Universidad de Guayaquil

CDDEIA-ELNO-4-2: Ciencia de Datos e Inteligencia Artificial

Msc. Darwin Rodríguez

11 de junio de 2026

Parte 1: Informe comparativo de Métricas

1. Introducción

El diagnóstico asistido por computadora para la detección de cáncer de mama es un hito importante en la medicina moderna, por ello el diagnóstico de estos podría ayudar de forma significativa; para la presente investigación se clasificarán los tumores como: Maligno (Clase 0) y Benigno (Clase 1).

Un error de clasificación tiene repercusiones importantes, catalogar un tumor maligno como benigno (un falso negativo) puede retrasar la apertura a un tratamiento crítico y altamente necesario en que la mayoría de los casos toma vidas humanas, debido a no actuar a tiempo. Mientras que catalogar un tumor benigno como maligno (un falso positivo) induce a estrés psicológico, procesos médicos innecesarios e incluso tratamientos inadecuados que pueden causar importante daño a la salud de una persona.

2. Comparación de métricas de evaluación

Diccionario de variables previo:

- TP(True Positives / Verdaderos Positivos)
- FN (False Negatives / Falsos negativos)
- TP + FP (Total de predicciones positivas sin importar si acertó o falló)
- TP + FN (Total de positivos reales)

Precisión (Precision)

Mide la calidad de las predicciones positivas del modelo. Se define como $TP/(TP+FP)$. En nuestro modelo base, la precisión fue de 0.9467 (94,67%). Significa que de cada 100 pacientes el modelo etiquetó como benignos a 95 personas que realmente lo eran y 5 que era falso positivo, realmente eran malignos.

Sensibilidad (Recall)

Mide la capacidad del modelo para encontrar todos los casos positivos reales. Su fórmula es $TP/(TP+FN)$. El modelo base obtuvo un 0.9861 (98.61%). Lo que indica que el sistema es sumamente eficaz para capturas casos de las clases analizadas (0-1), dejando muy pocos pacientes sin diagnosticar correctamente (Falsos negativos).

F1-Score

Es la media entre Precisión y Recall, calculada como $2 * (\text{Precision} \times \text{Recall}) / (\text{Precisión} + \text{Recall})$. Se utiliza para evaluar el balance general del modelo cuando existe un costo compartido entre Falsos Positivos y Negativos. El valor fue de 0.9660.

AUC-ROC (Área bajo la curva ROC)

Mide la capacidad global del modelo para separar las clases de todos los umbrales posibles. Un valor de 0.5 representa una clasificación aleatoria. El modelo alcanzó el 0.9940, demostrando ser altamente capaz de diferencia tejido sano de tejido cancerígenos.

3. Justificación de la Métrica más adecuada

Enfocado en la detección de clase maligna de cáncer de mama, la métrica más crítica es la de Recall (sensibilidad).

Justificación:

En medicina, siempre es algo de prioridad disminuir los errores como los falsos negativos, casos donde el paciente está enfermo, pero vuelve a casa porque cree o los resultados de una prueba lo clasifican como alguien sano. Un Recall, alto aseguraría que casi la totalidad de los pacientes con tumores malignos sean detectados para recibir debida atención. Si bien el de Precisión, es importante para evitar levantar falsas alarmas como falsos positivos, en medicina, es en la mayoría por no decir todos los casos, someter a un paciente sano a estudios confirmatorios secundarios que permitir que un paciente con cáncer avanzado pase desapercibido por el algoritmo debido a estar en el rango de fallo.

Parte 3: Conclusiones Analíticas

Debido a la gran cantidad de pruebas de laboratorio realizados y a la par de clasificar debidamente la información para futuro análisis de métricas, esa estructura de información facilita obtener valiosas lecciones sobre el comportamiento de la Regresión logística.

1. ¿Qué método de búsqueda de hiperparámetros fue más eficiente?

El análisis experimental determinó que RandomizedSearchCV demostró ser más eficiente que GridSearchCV, logrando una convergencia en el rendimiento con un ahorro del 53.7% en el tiempo de procesamiento.

GridSearchCV realizó una exploración exhaustiva de todo el espacio combinatorio, requiriendo un tiempo total de 4.7364 segundos para determinar que los mejores parámetros eran {'C': 10, 'penalty': 'l2'} con un F1-Score de 0.9596, mientras que RandomizedSearchCV seleccionó únicamente un subconjunto de iteraciones aleatorias y llegando coincidir exactamente a la misma combinación óptima con un F1-Score idéntico de 0.9596, pero en tan solo 2.1909 segundos.

Este empate resalta la superioridad práctica del muestreo aleatorio. En entornos de Big Data donde el entrenamiento puede tomar días, este comportamiento demuestra que RandomizedSearchCV es una estrategia preferencial para optimizar modelos de manera escalable sin sacrificar la calidad del diagnóstico médico.

2. ¿Cómo afectó el ajuste del umbral a Precisión vs Recall?

El ajuste del umbral de decisión demostró que el modelo entrenado posee una estabilidad matemática importante. Al evaluar un umbral bajo de 0.3, el modelo admitió casos dudosos logrando un Recall de 0.9861 y una Precisión de 0.9342. Al elevar dicho umbral a 0.5 y posteriormente a 0.7, el Recall permaneció completamente congelado en su valor máximo de 0.9861.

Esto indicaría que el clasificador asigna probabilidades extremadamente altas y seguras a los verdaderos positivos, impidiendo que el aumento en la exigencia del umbral genere falsos negativos.

Como consecuencia directa de este comportamiento, la Precisión escaló de manera continua hasta alcanzar un óptimo de 0.9595 en el umbral de 0.7.

Permitiendo que el umbral de 0.7 consolidara el F1-Score más alto del experimento (0.9726), demostrando que un umbral más exigente puede maximizar la calidad de las predicciones sin perjudicar la sensibilidad diagnóstica.

3. ¿y qué aprendiste sobre la elección de métricas?

Se aprendió que evaluar un modelo basándose únicamente en la Accuracy 0.9561 (exactitud), es un error importante. La exactitud puede camuflar deficiencias críticas si las clases están mínimamente desbalanceadas. En la matriz de confusión (38 malignos correctamente predichos frente a 4 falsos positivos, y 71 benignos frente a 1 falso negativo), las métricas desagregadas como Precisión y Recall, permiten auditar el comportamiento específico del motor antes diversos errores particulares.

La validación cruzada K-fold, corroboró dicho aprendizaje, al comparar $K = 5$ (Exactitud: 0.9508, Desviación: 0.0263) y luego $K=10$ (Exactitud: 0.9490, Desviación: 0.0337), se evidenció que aumentar el valor, incrementa la variabilidad del rendimiento. Lo que permite deducir que el modelo no depende solo de su algoritmo, también de como están o se segmentan los datos y la precisión conceptual con la que se interpretarían los fallos.

Bibliografía

- Bello, K., Ibidoja, O. J., & Abubakar, Y. (Julio de 2024). *Predicting Students Academic Performance using Ridge, LASSO and Elastic Net with Efficient Model Selection: A Case Study of Federal*. Obtenido de University Gusau Nigeria: <https://fugus-ijsgs.com.ng/index.php/ijsgs/article/download/670/439/734>
- Berrar, D. (2019). *Cross-Validation*. Encyclopedia of Bioinformatics and Computational Biology. Obtenido de https://dberrar.github.io/papers/Berrar_EBCB_2nd_edition_Cross-validation_preprint.pdf
- Casal, R. F., Bouzas, J. C., & Fuente, M. O. (2024). *Métodos predictivos de aprendizaje estadístico*. Obtenido de Github: https://rubenfcasal.github.io/aprendizaje_estadistico/aprendizaje_estadistico.pdf
- Chicco, D., & Jurman, G. (2020). *The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation*. BMC Genomics. Obtenido de <https://link.springer.com/article/10.1186/s12864-019-6413-7>
- Fawcett, T. (2006). *An introduction to ROC analysis*. Pattern Recognition Letters. Obtenido de <https://people.inf.elte.hu/kiss/13dwhdm/roc.pdf>
- Geeks for Geeks . (12 de julio de 2025). *Lasso vs Ridge vs Elastic Net - ML*. Obtenido de <https://www.geeksforgeeks.org/machine-learning/lasso-vs-ridge-vs-elastic-net-ml/>
- Google Developer Program. (2026). *Sobreajuste*. Obtenido de developers.google.com: <https://developers.google.com/machine-learning/crash-course/overfitting/overfitting?hl=es-419>
- Goutte, C., & Gaussier, B. (2005). *A Probabilistic Interpretation of Precision, Recall and F-Score, with Implication for Evaluation*. Lecture Notes in Computer Science. Obtenido de https://link.springer.com/chapter/10.1007/978-3-540-31865-1_25

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., . . . Duchesnay, E. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research. Obtenido de <https://jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf>

Powers, D. M. (2011). *Evaluation: From Precision, Recall and F-Measure to ROC Informedness, Markedness and Correlation*. Cornell University. Obtenido de <https://arxiv.org/pdf/2010.16061>

Saito, T., & Rehmsmeier, M. (2015). *The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets*. PLOS One. Obtenido de <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0118432>

Valverde-Albacete, F. J., & Peláez-Moreno, C. (2014). *100% classification accuracy considered harmful*. PLOS One. Obtenido de <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0084217>

